

Тестовое задание — аналитик данных DaData

Задание 1. Справочник «организация — официальный сайт»

Цель и принципы

Нужно дополнить сервис «Организация по ИНН» доменом официального сайта. Для такого поля существенно важнее точность, чем полнота: ошибочно привязать сайт одноимённой организации, франшизы или холдинга хуже, чем вернуть пустое значение. Поэтому домен — сущность с доказательствами и уровнем уверенности, а не необратимое текстовое поле.

Сбор данных

Первый слой — карточка юридического лица из DaData/официальных источников: ИНН, полное и сокращённое наименование, ОГРН, адрес, руководитель, статус и, если поставщик его отдаёт, web-домен. Он решает entity resolution: поиск ведётся не только по бренду, но и по точной юридической сущности.

Второй слой — поиск кандидатов. Формирую несколько запросов: точное название + ИНН, название + «официальный сайт», бренд + адрес. Из Web Search беру URL, title, snippet, дату/регион, если они доступны. Дополнительно можно использовать официальный реестр, страницы контрагентов, реквизиты на сайтах и открытые API. URL нормализую до hostname: убираю www, параметры, дубли и очевидно нецелевые платформы — поисковики, соцсети, карты и агрегаторы.

Для масштабного наполнения применил бы двухконтурную схему. Высокоуверенные записи создаются автоматически, спорные попадают в review-очередь с собранными доказательствами. Это даёт контролируемый старт без ручной проверки всего реестра.

Оценка качества

Кандидат получает признаки: точное совпадение названия/ИНН в тексте сайта, совпадение адреса/ОГРН, наличие разделов «контакты» и реквизитов, совпадение бренда в title, независимые подтверждения несколькими источниками, история домена. LLM используется как рецензент доказательств, но не как источник истины: ей передаётся ограниченный пакет evidence и предписывается выбрать домен или null.

Решение проходит детерминированную проверку: выбранный домен обязан быть среди найденных URL, иметь supporting URL из evidence, не попадать в blacklist платформ и иметь medium/high confidence. При конфликте или недостатке доказательств возвращается null.

Качество измеряю на размеченной выборке: precision принятых доменов, coverage, доля null, доля спорных записей, расхождения при повторной проверке и latency. Для приёмки отдельно проверю длинный хвост: одинаковые названия, группы компаний, ликвидированные юрлица, переезды и домены с редиректами.

Актуализация

Для каждой записи храню ИНН, fingerprint исходной карточки, домен, confidence, evidence URLs, timestamps и результат ручной проверки. Переобогащение запускается по TTL; ускоренно — при изменении названия/адреса/статуса, падении сайта, сигнале от пользователя или низкой уверенности. Изменение домена не перезаписывает старый результат молча: новая версия получает собственные evidence и может требовать review.

Открытые вопросы и ограничения

Не у каждой организации есть индексируемый сайт. Есть холдинги, торговые марки, филиалы, сайты на конструкторах и устаревшие snippets. Юридическое имя может не совпадать с брендом. Эти случаи — причина предпочесть null ложному совпадению. Также нужны политика хранения персональных данных, лимиты и условия внешних API, мониторинг стоимости поиска/LLM и feedback от пользователей.

Задание 2. Python агентный пайплайн

Репозиторий: <https://github.com/bigidulka/dadata-inn-site-finder>

Контракт

Вход: ИНН из 10 или 12 цифр. Выход всегда имеет минимальный JSON-контракт:

```
{"domain": "dadata.ru"}  
# или  
{"domain": null}
```

Архитектура

1. DaDataClient получает карточку организации по ИНН.
2. BraveSearchClient ищет кандидаты запросом из полного имени, ИНН и «официальный сайт».
3. Нормализатор приводит URL к hostname и фильтрует поисковые/социальные/агрегаторные домены.
4. OpenAICompatibleAssessor получает строго ограниченную карточку сущности и evidence, возвращает structured JSON: domain, confidence, rationale, supporting_urls.
5. SiteFinder принимает ответ только после детерминированной валидации кандидата и цитаты; в остальных случаях возвращает null.

Агенты разделены по ответственности: внешние API собирают факты, LLM сопоставляет доказательства, код контролирует инварианты контракта. Ключи передаются только через переменные окружения и не логируются.

Инструменты и проверка

Использованы Python 3.11+, requests, DaData API, Brave Search API и OpenAI-compatible Chat Completions API. Провайдер и модель LLM конфигурируемы, поэтому можно выбрать доступный API с пробным лимитом из перечня задания. Проект покрыт четырьмя pytest-тестами с HTTP-фейками: пример задания 7721581040 dadata.ru, галлюцинация LLM, запрещённый/низкоуверенный домен и валидация ИНН/URL. Локальный прогон: 4 passed.

Для настоящего запуска задаются DADATA_API_KEY, BRAVE_SEARCH_API_KEY, LLM_API_KEY; затем dadata-site-finder 7721581040 делает реальный поиск и выдаёт итоговый JSON. Реальные ключи не включались в репозиторий и не подменялись фиктивными результатами.